

Análisis técnico y go/no-go

RFI — Asistente Virtual de Consultas Fiscales · Grupo San Cristóbal

Documento: Evaluación interna de viabilidad · **Fecha:** 30 de junio de 2026 · **RFI:** v1.0 — "Implementación de Asistente Virtual de Consultas Fiscales"
Plazo de respuesta: 08 de julio de 2026 · **Naturaleza:** documento interno · tono crudo (decisión go/no-go) · sin endulzar

1. Resumen ejecutivo

Grupo San Cristóbal (asegurador) busca un **asistente virtual de IA para consultas fiscales**. Hoy su equipo de Impuestos responde manualmente, vía **tickets de Jira**, consultas de clientes y Productores de Seguros. El RFI pide un chatbot que: (a) construya una base de conocimiento desde **tickets de Jira resueltos**, (b) responda automático lo frecuente, (c) **proponga respuesta con validación humana** en casos similares, (d) **derive a Jira** los casos nuevos, con **Microsoft Teams** como canal de Atención al Cliente.

VEREDICTO: GO con encuadre honesto.

El núcleo del RFI —RAG sobre el conocimiento del cliente + agente conversacional en español rioplatense + human-in-the-loop + multi-canal + trazabilidad— **es exactamente nuestra zona de fortaleza**: ya está construido y operando en la plataforma de "Empleados Digitales" (Aura). El gap real **no es de inteligencia artificial**: es de **integración con el ecosistema Microsoft/Jira** y de **madurez enterprise** (SSO real, SLA 99%, multi-usuario, privacidad).

Dato decisivo: Jira **ya está operativo** en el cliente y la infraestructura Microsoft (Teams, Entra, M365) **la provee el cliente** bajo su licenciamiento. No hay que *construir* el ecosistema: hay que *conectar adapters* a sistemas que el cliente ya opera. El riesgo de integración baja drásticamente.

Como POC/demo estamos muy alineados. Como contrato enterprise hay plomería e infraestructura no trivial —pero viable—, con dos gaps que sí exigen seriedad antes de firmar: la **privacidad del proveedor LLM** (R5) y la **cola de validación de borradores** (§3.2).

2. Qué pide el RFI (síntesis)

Bloque	Exigencia
Objetivo (§2)	KB desde tickets Jira resueltos · respuesta automática a frecuentes · propuesta con validación humana · derivación a Jira de casos nuevos · canal Teams
Base de conocimiento (§3.1)	Extracción desde tickets · clasificación por casuística fiscal · actualización continua · panel de administración
Motor de respuesta (§3.2)	Clasificar en 3 categorías (exacta / similitud alta / nuevo) · auto-respuesta · propuesta-con-validación · derivación a Jira con resumen
Teams (§3.3)	Bot para Atención al Cliente · conversación natural · notificaciones al analista
Integraciones (§3.4)	Jira (REST/webhook) · Teams (Azure Bot/Graph) · Confluence (opcional)
Requisitos (§4)	R1 NLP español fiscal · R2 umbral configurable · R3 trazabilidad · R4 panel admin · R5 privacidad/Ley 25.326 · R6 SLA 99% · R7 escalabilidad · R8 SSO Azure AD
Fuera de alcance (§5)	Canales externos (email/WhatsApp/web), dictámenes legales, ERP, multilingüe

3. Qué tenemos hoy (plataforma "Empleados Digitales")

- **Orquestación:** OpenAI Agents SDK + FastAPI. Capa de canal **desacoplada** del cerebro (`agent_service.chat()`) agnóstico de canal).
- **RAG / base de conocimiento:** ChromaDB + embeddings `text-embedding-3-small` ; ingesta PDF/MD/TXT; **re-ingesta en caliente sin redeploy**; retrieval con **score de similitud**, top-k, dedup y umbral, con **atribución de fuente**.
- **Gestión de conocimiento:** backoffice con CRUD de entradas/documentos, activar/desactivar, entrenamiento por agente.
- **Human-in-the-loop: takeover** humano persistido en DB con auto-release (10 min); pre-resolución de tickets con validación.
- **Tickets internos:** estados, eventos/auditoría, asignación por área.
- **Multi-agente:** tres roles (huésped/gerencia/operaciones), cada uno con legajo, skills, entrenamiento y métricas.
- **Skills con "techo duro":** parámetros del cliente validados/recortados server-side (`policy_values`) — ajusta perillas sin romper el motor.

- **Trazabilidad:** log por mensaje (rol, contenido, modelo, tokens, **fuentes**, contexto) + audit JSONL.
- **Canales:** web chat + WhatsApp (Twilio). **LLM:** OpenAI `gpt-4o` (un solo proveedor). **Auth:** sólo `X-Admin-Key`.

4. Mapa de cobertura RFI → plataforma

✓ ya existe · ● existe el patrón, hay que adaptar · ● hay que construir/integrar

#	Requisito RFI	Estado	Qué tenemos / qué falta
2 / 3.1	KB desde tickets Jira resueltos	●	RAG completo con re-ingesta en caliente. Ingesta hoy PDF/MD/TXT. Falta: conector Jira→RAG. El motor ya está; falta la "boca" de Jira.
3.1	Clasificación por casuística fiscal	●	Patrón de clasificación con LLM ya existe. Falta: taxonomía fiscal (retenciones, IVA, IIBB...). Prompt/datos, no arquitectura.
3.1	Actualización continua	●	Re-ingesta en caliente ya existe. Falta: webhook Jira "ticket cerrado". Directo, Jira ya vivo.
3.1 / R4	Panel de administración	✓ ●	CRUD de conocimiento y docs ya existe. Falta: vista curada "entradas de Jira". Reutiliza el panel.
3.2	3 bandas: exacto / alto / nuevo	●	El RAG ya devuelve score de similitud y filtra por umbral. Materializar las bandas es configuración sobre lo que ya medimos.
3.2 / R2	Umbral configurable (auto/validar/derivar)	●	Tenemos similitud + analizador de escalación. Falta: exponer el umbral como perilla configurable — calza en el patrón Skills + techo duro ya construido.
3.2	Auto-respuesta en coincidencia exacta	✓	El agente ya responde solo desde RAG. Portar es trivial.
3.2	Propuesta de respuesta con validación	●	Lo más cercano: takeover + pre-resolución. Falta "IA redacta borrador → cola de validación → analista aprueba/edita → envía". Gap funcional #1.
2 / 3.2	Derivar caso nuevo → ticket Jira	● ●	Tenemos creación interna de tickets + resumidor LLM. Falta: conector de salida a Jira. Riesgo bajo (Jira vivo).
3.3	Canal Microsoft Teams	●	Hoy web + WhatsApp; canal desacoplado. Falta: adapter de Teams (Azure Bot Service). El cliente pone la infra. Gap de canal #1.
R1	NLP español rioplatense + fiscal AR	✓	Aura ya es voseo rioplatense nativo. Terminología fiscal = conocimiento. Fuerte.
R3	Trazabilidad completa	✓ ●	Ya logueamos pregunta/respuesta/modelo/tokens/ fuentes . Falta: campo "validado por humano / quién / cuándo".
R5	Privacidad: datos no salen · Ley 25.326	●	Hoy OpenAI cloud. Choca de frente. Camino: Azure OpenAI en tenant del cliente + abstracción de proveedor. El gap más sensible.
R6	Alta disponibilidad, SLA 99%	● ●	Tenemos circuit breaker + retries. Falta: HA real, SLA operativo, on-call. Infra, no producto.
R7	Escalabilidad por volumen	●	Stateless + Postgres + Chroma. Razonable; no probado a volumen enterprise.
R8	SSO / Azure AD (Entra) / M365	●	Hoy sólo <code>X-Admin-Key</code> . Falta: OIDC/SAML contra el tenant del cliente, con roles.
3.4	Confluence (opcional)	●	Mismo patrón que Jira: conector REST→RAG. Diferible.
5	Fuera de alcance fase 1	✓	Nos juega a favor: lo que excluyen es lo que no tenemos pulido para fiscal. Reduce alcance.

5. Fortalezas que nos posicionan (no improvisamos)

- **Motor RAG con re-ingesta en caliente** — el corazón del RFI (§3.1) ya funciona en producción.
- **Score de similitud del RAG** — base directa para las "3 bandas" del §3.2.
- **Patrón "Skills + techo duro"** (`policy_values` validados server-side) — es *literalmente* el "umbral configurable" del R2.
- **Human-in-the-loop real** — takeover persistido en DB; base sólida para montar la validación humana.
- **Trazabilidad por mensaje con atribución de fuente** — R3 casi cubierto de fábrica.
- **Agente español rioplatense nativo** — R1 casi gratis. **Capa de canal desacoplada** — Teams es un adapter, no un rediseño.
- **"Empleado Digital que rinde cuentas"** — diferenciador frente a "un chatbot que responde": legajo, skills, métricas y parte de fin de día por agente.

6. Gaps a cubrir (por peso y riesgo)

Prio.	Gap	Por qué importa	Camino recomendado
● 1	Privacidad / proveedor LLM (R5)	"Los datos no salen del entorno" + Ley 25.326. Hoy todo va a OpenAI cloud. Condición de cumplimiento, no opcional.	Azure OpenAI en tenant/región del cliente + abstraer el provider.
● 2	Cola de validación de borradores (§3.2)	Corazón funcional del RFI ("IA propone → analista valida → envía"); hoy en alpha (sólo takeover).	Workflow + estado "pendiente de validación" + UI de cola + registro de quién validó.
● 3	Conector Jira bidireccional	Entrada (tickets→RAG + webhook) y salida (caso nuevo→issue con resumen).	API REST de Jira (ya vivo). Riesgo bajo, hay que escribirlo.
● 4	Adapter Microsoft Teams (§3.3)	Canal exigido + notificaciones al analista.	Azure Bot Service / Bot Framework contra <code>agent_service.chat()</code> .
● 5	SSO Entra ID + multi-usuario (R8)	De header compartido a auth corporativa con roles.	OIDC/SAML contra el tenant Entra del cliente.
● 6	Umbral de 3 bandas configurable (R2/3.2)	Materializar exacto/alto/nuevo sobre el score del RAG, como perilla.	Extiende el modelo de Skills/techo duro. Bajo riesgo.
● 7	Taxonomía fiscal + clasificación (3.1)	Categorías fiscales en prompt/datos.	Trabajo de dominio, no de arquitectura.
● 8	HA / SLA 99% (R6)	Despliegue redundante + operación.	Infra/operación, idealmente sobre Azure del cliente.

7. Estimación de esfuerzo (orden de magnitud)

Estimación gruesa para dimensionar, **no compromiso**. Supone equipo chico (1–2 devs) y que el cliente provee accesos a Jira/Teams/Entra y entorno Azure. Unidad: semanas-persona.

Gap	Esfuerzo	Riesgo	Notas
Conector Jira (in + webhook + out)	1.5–2.5 sem	Bajo	API REST conocida; Jira operativo.
Taxonomía fiscal + clasificación	1–2 sem	Bajo	Depende de calidad/volumen de tickets históricos.
Umbral 3 bandas configurable	1–1.5 sem	Bajo	Reusa <code>policy_values</code> / techo duro.
Cola de validación de borradores	2.5–4 sem	Medio	Workflow + estados + UI + trazabilidad de validación.
Adapter Microsoft Teams	2–3 sem	Medio	Bot Framework/Azure Bot; depende de accesos.
Azure OpenAI + abstracción de proveedor	1.5–3 sem	Medio-alto	Migración de provider + paridad de calidad.
SSO Entra ID + roles multi-usuario	2–3 sem	Medio	OIDC + RBAC en backoffice.
HA / SLA 99% (infra)	2–4 sem	Medio	Redundancia + observabilidad + on-call (continuo).
Total POC Fase 1 (Jira + RAG + 3 bandas + validación + Teams mínimo + Azure OpenAI)	~8–12 sem	Medio	Alcance acotado, sin SSO enterprise ni SLA 99%.
Total contrato enterprise (todo + HA + SSO)	~14–22 sem	Medio-alto	Incluye endurecimiento operativo.

8. Fundamentos de la recomendación

- **El RFI cae sobre nuestra zona de fortaleza.** RAG, agente en español, HITL y trazabilidad ya operan. No partimos de cero en lo difícil (el motor); sí en lo conocido (integraciones).
- **El miedo principal —las integraciones Microsoft/Jira— se desinfla.** El cliente ya opera Jira, Teams y Entra. Conectamos adapters; no construimos el ecosistema. Baja riesgo y costo.
- **Lo que sí exige seriedad antes de firmar** son dos cosas acotadas: privacidad (Azure OpenAI) y la cola de validación. Ambas alcanzables y bien delimitadas.

- **Lo que el cliente excluye nos favorece.** Email/WhatsApp/web externos, dictámenes, ERP y multilingüe quedan fuera de fase 1 — justo lo no pulido para fiscal.
- **La jugada no es competir en "el motor"** (se comoditiza), sino en **vertical + cercanía + Azure-nativo**: el implementador que entiende el dominio fiscal AR y se integra limpio al stack Microsoft que el cliente ya tiene.

Riesgo a vigilar (honesto): somos un equipo chico frente a un asegurador que pedirá referencias en sector financiero, SLA y cumplimiento de Ley 25.326. No prometer en fase 1 lo propio de un proveedor enterprise grande (SLA 99% contractual, SSO completo, on-call 24/7). Acotar la POC y crecer por etapas.

9. Recomendación y próximos pasos

GO con alcance por etapas.

- **Para responder el RFI (vence 08-jul):** posicionar fortalezas reales (RAG, español rioplatense, HITL, trazabilidad, "empleado digital que rinde cuentas"), declarar gaps con honestidad, y proponer una **POC Fase 1 acotada**: Jira-in → RAG → respuesta automática / propuesta-con-validación, sobre **Azure OpenAI**, con un **adapter mínimo de Teams**. No comprometer SLA 99% ni SSO enterprise en fase 1.
- **Si avanza:** dimensionar formalmente los gaps  (Azure OpenAI, cola de validación, conector Jira, adapter Teams, SSO Entra) en un plan con hitos y dependencias de accesos del cliente.

Anexo — Archivos de la plataforma (reuso, no reinención)

Componente	Ubicación
RAG / re-ingesta	backend/app/services/rag_service.py , vector_store.py , routers/knowledge.py , routers/documents.py
Human-in-the-loop / validación	services/conversation_control_service.py , routers/hotel_tickets.py (pre-resolve), services/escalation_analyzer.py
Umbral configurable (Skills/techo duro)	landing/src/admin/views/centro/EmployeeSkills.jsx + modelo policy_values
Canal desacoplado / entrada agnóstica	services/agent_service.py (chat()), routers/whatsapp.py (referencia de adapter)
LLM provider (a abstraer para Azure OpenAI)	core/openai_client.py , app/config.py
Auth (a reemplazar por SSO)	core/admin_auth.py
Trazabilidad	models/conversation_message.py , audit logs/aura_audit.jsonl
Estrategia / visión de producto	FLUJOS_Y ESTRATEGIA.md

Documento interno de evaluación. No constituye oferta ni compromiso contractual. Estimaciones de esfuerzo en orden de magnitud, sujetas a relevamiento de accesos e infraestructura del cliente.